

Лабораторная работа №5

Задача регрессии

Дмитрий Коваль, Георгий Лаврентьев
группа М3232

2 июня 2026 г.

1 Постановка задачи

Рассматривается задача восстановления регрессионной зависимости по зашумлённым данным. По выборке $\{(x_i, y_i)\}_{i=1}^m$ строится параметрическая модель $\hat{y}(x, w)$, а вектор параметров $w \in \mathbb{R}^p$ выбирается из условия минимизации эмпирического риска

$$Q(w) = \frac{1}{m} \sum_{i=1}^m (\hat{y}(x_i, w) - y_i)^2 \longrightarrow \min_w.$$

При наличии регуляризации минимизируется полная функция потерь

$$L(w) = Q(w) + \lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2.$$

В работе реализованы и исследованы две модели регрессии (линейная и полиномиальная), четыре варианта функции потерь (без регуляризации, L_1 , L_2 и Elastic Net) и пять методов оптимизации:

1. аналитическое решение линейной регрессии через оценки средних (одномерный случай);
2. стохастический градиентный спуск (SGD);
3. mini-batch градиентный спуск;
4. метод Гаусса–Ньютона;
5. метод Гаусса–Ньютона с регуляризацией Левенберга–Марквардта.

Единый интерфейс и подсчёт затрат. Модели имеют единый интерфейс (`design` — построение матрицы плана, `predict` — предсказание), а оптимизаторы — единую сигнатуру запуска вида

$$\text{optimizer}(\text{problem}, w_0, \dots) \longrightarrow \text{RegressionResult},$$

где `problem` инкапсулирует матрицу плана Φ , целевой вектор y и параметры регуляризации, а `RegressionResult` содержит найденный вектор w , итоговые значения L , Q и регуляризатора, а также историю этих величин и учётные показатели:

1. число итераций / эпох;

2. число вычислений градиента (число обработанных батчей);
3. время работы;
4. причину остановки.

Для SGD и mini-batch дополнительно фиксируются размер батча, число эпох и правило выбора шага. Подсчёт вызовов оракулов доступен через декоратор-счётчик `CallCounter`; все векторно-матричные операции выполнены средствами `NumPy`.

Причины остановки. Методы возвращают различные статусы завершения:

- *Сходимость по градиенту* — выполнено $\|\nabla L(w_k)\| \leq \varepsilon$;
- *Сходимость по функции потерь* — относительное изменение потерь за эпоху опустилось ниже порога, $|L_{k+1} - L_k| \leq \text{tol} (1 + |L_k|)$;
- *Сходимость (шаг не уменьшает потери)* — в методе Левенберга–Марквардта параметр демпфирования вырос настолько, что ни один шаг не уменьшает L , при малом градиенте;
- *Достигнут лимит эпох / итераций* — исчерпан бюджет шагов;
- *Расходимость* — значение потерь перестало быть конечным;
- *Аналитическое решение* — решение получено в замкнутой форме.

2 Генерация данных

Данные генерируются на основе аналитических функций с добавлением нормального шума

$$y_i = f_{\text{true}}(x_i) + \xi_i, \quad \xi_i \sim \mathcal{N}(0, \sigma^2),$$

где точки x_i равномерно распределены на отрезке $[-3, 3]$, а объём каждой выборки $m = 160$ (≥ 100 согласно условию). Рассматриваются два набора данных.

Почти линейная зависимость.

$$f_{\text{true}}(x) = 0.8x - 0.5 + 0.1 \sin(3x), \quad \sigma = 0.35.$$

Слагаемое $0.1 \sin(3x)$ задаёт слабое отклонение от прямой.

Сильно нелинейная зависимость.

$$f_{\text{true}}(x) = \sin(2x) + 0.15x^3 - 0.5x + 1.5 \exp\left(-\frac{(x-1)^2}{0.1}\right), \quad \sigma = 0.45.$$

Здесь сочетаются периодическая часть $\sin(2x)$, полиномиальный тренд $0.15x^3 - 0.5x$ и локальный пик в окрестности $x = 1$.

Истинная зависимость, дисперсия шума и диапазон x для обеих задач явно зафиксированы выше.

3 Модели регрессии

Определение 3.1 (Полиномиальная модель). Моделью полиномиальной регрессии степени d называется

$$\hat{y}(x, w) = \sum_{j=0}^d w_j \varphi_j(x),$$

где φ_j — признаки, построенные из x . Линейная регрессия соответствует $d = 1$.

Модель линейна по параметрам w , поэтому на выборке предсказания записываются через *матрицу плана* $\Phi \in \mathbb{R}^{m \times (d+1)}$ со строками $\varphi(x_i) = (1, z_i, z_i^2, \dots, z_i^d)$ и

$$\hat{y} = \Phi w.$$

Согласно рекомендации условия, входной признак предварительно нормируется, $z = (x - \bar{x})/s_x$, после чего столбцы матрицы плана дополнительно центрируются и масштабируются к единичной дисперсии (кроме свободного столбца). Это существенно уменьшает число обусловленности задачи: для нормированного базиса при степени $d = 5$ оно составляет $\kappa \approx 5 \cdot 10^2$, тогда как для «сырого» базиса Вандермонда той же степени κ на несколько порядков больше (см. раздел 6.4).

4 Функции потерь и регуляризация

Эмпирический риск и его градиент для модели, линейной по параметрам, имеют вид

$$Q(w) = \frac{1}{m} \|\Phi w - y\|_2^2, \quad \nabla Q(w) = \frac{2}{m} \Phi^\top (\Phi w - y).$$

Регуляризованная функция потерь

$$L(w) = Q(w) + \lambda_1 \sum_{j \geq 1} |w_j| + \lambda_2 \sum_{j \geq 1} w_j^2$$

охватывает все четыре требуемых варианта: $\lambda_1 = \lambda_2 = 0$ (без регуляризации), только $\lambda_1 > 0$ (L_1), только $\lambda_2 > 0$ (L_2) и $\lambda_1, \lambda_2 > 0$ (Elastic Net). Свободный коэффициент w_0 не штрафуются.

Замечание 4.1 (Сглаживание L_1). Модуль недифференцируем в нуле, поэтому, как допускает условие, используется гладкая аппроксимация

$$|w_j| \approx \sqrt{w_j^2 + \varepsilon^2}, \quad \frac{\partial}{\partial w_j} \sqrt{w_j^2 + \varepsilon^2} = \frac{w_j}{\sqrt{w_j^2 + \varepsilon^2}},$$

с малым $\varepsilon = 10^{-6}$. Это позволяет применять к L_1 и Elastic Net те же градиентные методы, что и к гладким потерям.

5 Методы оптимизации

5.1 Аналитическое решение (одномерный случай)

Для линейной регрессии с одним признаком оптимальные коэффициенты выражаются через оценки средних:

$$\hat{w}_1 = \frac{\sum_i (z_i - \bar{z})(y_i - \bar{y})}{\sum_i (z_i - \bar{z})^2}, \quad \hat{w}_0 = \bar{y} - \hat{w}_1 \bar{z}.$$

Это точное решение задачи наименьших квадратов в одномерном случае, не требующее итераций; оно используется как эталон для линейной модели.

5.2 Градиентный спуск, SGD и mini-batch

Следуя общей логике модификаций градиентного спуска (Лекция 7), итерационные методы записываются в форме

$$w_{k+1} = w_k - \alpha_k p_k,$$

где для базового спуска $p_k = \nabla L(w_k)$. В стохастической постановке полный градиент заменяется его оценкой по случайному подмножеству (батчу) $B \subseteq \{1, \dots, m\}$:

$$\widehat{\nabla}Q(w) = \frac{2}{|B|} \Phi_B^\top (\Phi_B w - y_B),$$

к которой добавляется точный градиент регуляризатора. Метод SGD соответствует $|B| = 1$, mini-batch — промежуточным значениям $1 < |B| < m$, а полный батч $|B| = m$ даёт обычный градиентный спуск. Одна *эпоха* — это один проход по случайно перемешанной выборке; число вычислений градиента равно числу обработанных батчей.

Правило выбора шага. Используется убывающий по времени шаг

$$\alpha_t = \frac{\alpha_0}{1 + \gamma t},$$

где t — номер обновления, α_0 — начальный шаг, γ — скорость затухания (поддерживается и постоянный шаг). Затухание обеспечивает устойчивость стохастических методов вблизи минимума, где шум оценки градиента не позволяет точно остановиться.

5.3 Метод Гаусса–Ньютона

Для задачи наименьших квадратов с вектором невязок $r(w) = \Phi w - y$ и якобианом $J = \partial r / \partial w = \Phi$ (постоянным, так как модель линейна по параметрам) метод Гаусса–Ньютона приближает гессиан риска матрицей $\frac{2}{m} J^\top J$ и делает шаг

$$w_{k+1} = w_k - H^{-1} \nabla L(w_k), \quad H = \frac{2}{m} \Phi^\top \Phi + H_{\text{рег}},$$

где $H_{\text{рег}}$ — диагональный вклад гладкого регуляризатора. Для модели, линейной по параметрам, шаг Гаусса–Ньютона совпадает с решением нормальных уравнений, поэтому метод сходится за одну итерацию (вторая итерация лишь подтверждает $\|\nabla L\| \leq \varepsilon$).

5.4 Метод Левенберга–Марквардта

Левенберг–Марквардт демпфирует систему Гаусса–Ньютона параметром $\mu \geq 0$:

$$(H + \mu I) \Delta = \nabla L(w_k), \quad w_{k+1} = w_k - \Delta.$$

Согласно условию, реализовано правило адаптации μ : если пробный шаг уменьшает потери, он принимается, а μ уменьшается ($\mu \leftarrow \mu / \nu$); если нет — шаг отклоняется, а μ увеличивается ($\mu \leftarrow \mu \cdot \nu$) до тех пор, пока шаг не станет успешным (в работе $\mu_0 = 10^{-2}$, $\nu = 3$). При $\mu \rightarrow 0$ метод приближается к Гауссу–Ньютону, при больших μ — к мелкому шагу вдоль антиградиента. Демпфирование делает метод устойчивым на плохо обусловленных задачах, где прямое решение нормальных уравнений ненадёжно.

6 Экспериментальная часть

6.1 Задание 1: базовые модели без регуляризации

Для обеих задач обучены линейная и полиномиальные (степеней 2–5) модели всеми применимыми методами. В таблицах 1 и 2 приведён итоговый эмпирический риск Q .

Таблица 1: Почти линейная: итоговый эмпирический риск Q


Степень	Аналит	SGD	MB	GN	LM
1	0.1464	0.1464	0.1464	0.1464	0.1464
2	—	0.1463	0.1463	0.1463	0.1463
3	—	0.1450	0.1451	0.1450	0.1450
4	—	0.1447	0.1448	0.1447	0.1447
5	—	0.1452	0.1436	0.1433	0.1433

Таблица 2: Сильно нелинейная: итоговый эмпирический риск Q


Степень	Аналит	SGD	MB	GN	LM
1	0.7466	0.7466	0.7466	0.7466	0.7466
2	—	0.7459	0.7460	0.7459	0.7459
3	—	0.7331	0.7332	0.7331	0.7331
4	—	0.7325	0.7327	0.7325	0.7325
5	—	0.4298	0.2965	0.2929	0.2929

Аналитическое решение, Гаусс–Ньютон и Левенберг–Марквардт достигают одного и того же минимума наименьших квадратов (значения совпадают до четырёх знаков), что подтверждает корректность реализаций. Для почти линейной задачи рост степени почти не уменьшает риск: зависимость и так близка к прямой. Для нелинейной задачи риск резко падает при переходе к степени 5 ($0.73 \rightarrow 0.29$): только полином достаточной степени способен описать локальный пик.

Метод mini-batch практически достигает оптимума наименьших квадратов, тогда как SGD при том же бюджете эпох заметно отстаёт на высокой степени — это закономерное следствие плохой обусловленности (см. рис. 2, зелёная кривая).




(a) Почти линейная: полиномы разных степеней.




(b) Нелинейная: полиномы разных степеней.

Рис. 1: Аппроксимация полиномами разных степеней (решение Гаусса–Ньютона). Для нелинейной задачи только степень 5 улавливает форму зависимости.




(a) Почти линейная, степень 1.



(b) Нелинейная, степень 5.

Рис. 2: Сравнение методов на одной модели. Точные методы (аналит., GN, LM) и mini-batch совпадают; SGD на нелинейной задаче недообучен при том же числе эпох.



(a) Почти линейная.



(b) Нелинейная.

Рис. 3: Динамика функции потерь по эпохам для итерационных методов SGD и mini-batch.

6.2 Задание 2: влияние размера batch

На нелинейной задаче с полиномом степени 5 метод mini-batch запущен при размерах батча 1, 4, 8, 16, 32, 64, m с одинаковыми шагом, затуханием и числом эпох. Итоговые

показатели сведены в таблицу 3.

Таблица 3: Влияние размера batch (нелинейная, степень 5)

batch	Итоговый риск	Эпохи	grad_calls	Время, с	Сошлось
1	4.2642e-01	200	32000	0.224	×
4	4.6821e-01	200	8000	0.059	×
8	4.9666e-01	200	4000	0.032	×
16	5.2875e-01	200	2000	0.018	×
32	5.6312e-01	200	1000	0.011	×
64	5.8895e-01	200	600	0.008	×
160	6.3848e-01	200	200	0.006	×




Рис. 4: Динамика потерь при разных размерах батча.

При фиксированном числе эпох меньший батч даёт больше обновлений за эпоху и потому быстрее снижает потери *по эпохам*: за 200 эпох $|B| = 1$ доходит до риска ≈ 0.43 , а полный батч — лишь до ≈ 0.64 . Платой за это служат шум траектории и существенно большее число вычислений градиента (32000 против 200). В пересчёте *на одну эпоху* крупные батчи дешевле и стабильнее. Разумным компромиссом для данной задачи оказались средние размеры $|B| = 8$ –16: они сочетают приемлемую скорость убывания потерь с устойчивостью траектории.

6.3 Задание 3: влияние регуляризации


Переобучение демонстрируется на нелинейной задаче с полиномом высокой степени ($d = 9$). Базовая модель без регуляризации сравнивается с L_1 , L_2 и Elastic Net при нескольких значениях параметров (таблица 4); модули коэффициентов до и после регуляризации приведены в таблице 5.

Таблица 4: Сводка по регуляризации (нелинейная, степень 9)


Тип	λ_1	λ_2	Риск Q	Рег.	Потери L	Ненулевых
L1	0.050	0.000	4.9698e-01	1.0717e-01	6.0415e-01	8
L2	0.000	0.050	5.0781e-01	5.6776e-02	5.6459e-01	9
Elastic Net	0.020	0.020	4.8486e-01	8.4158e-02	5.6901e-01	9

Таблица 5: Модули коэффициентов $|w_j|$


Индекс	База (без рег.)	L1	L2	Elastic Net
0	0.069	0.069	0.069	0.069
1	4.035	0.412	0.355	0.474
2	1.553	0.003	0.049	0.001
3	16.563	0.848	0.732	0.993
4	8.132	0.005	0.027	0.002
5	25.738	0.002	0.127	0.002
6	13.148	0.013	0.060	0.030
7	16.582	0.000	0.341	0.268
8	6.623	0.003	0.009	0.004
9	3.891	0.856	0.578	0.683



(a) L_1 .




(b) L_2 .




(c) Elastic Net.

Рис. 5: Динамика полных потерь L , эмпирического риска Q и регуляризатора по эпохам.



(a) Аппроксимация.



(b) Модули коэффициентов (лог. шкала).

Рис. 6: Влияние регуляризации на аппроксимацию и на структуру коэффициентов модели степени 9.

Без регуляризации модель степени 9 переобучается: коэффициенты достигают величин порядка 10–25, а кривая повторяет шум (рис. 6). Все три типа регуляризации резко уменьшают модули коэффициентов и сглаживают аппроксимацию. Различие между типами проявляется в структуре решения: L_1 и Elastic Net обнуляют часть коэффициентов (в таблице 5 у них 5–6 ненулевых весов из 9), давая разрежённое решение, тогда как L_2 равномерно сжимает все коэффициенты, не зануляя их. Это согласуется с известными свойствами L_1 - и L_2 -штрафов.

6.4 Задание 4: сравнение методов оптимизации

Сводное сравнение методов по итоговому риску, числу итераций/эпох, числу вычислений градиента и времени приведено в таблице 6.

Таблица 6: Сравнение методов оптимизации

Постановка	Метод	Риск Q	Итер/эпох	grad_calls	Время, с	Сошлось
Почти линейная, степень 1	Аналит	1.4639e-01	1	0	0.000	✓
Почти линейная, степень 1	SGD	1.4639e-01	256	40960	0.283	✓
Почти линейная, степень 1	MB	1.4639e-01	400	4000	0.036	×
Почти линейная, степень 1	GN	1.4639e-01	2	2	0.000	✓
Почти линейная, степень 1	LM	1.4639e-01	5	5	0.000	✓
Нелинейная, степень 5	SGD	4.2976e-01	400	64000	0.448	×
Нелинейная, степень 5	MB	2.9655e-01	400	4000	0.036	×
Нелинейная, степень 5	GN	2.9289e-01	2	2	0.000	✓
Нелинейная, степень 5	LM	2.9289e-01	7	7	0.001	✓

Точные методы (аналит., GN, LM) достигают минимума за единицы итераций и доли миллисекунды. Первопорядковые методы требуют сотен эпох и тысяч–десятков тысяч вычислений градиента; SGD при этом наименее эффективен на плохо обусловленной задаче. Статус «×» у SGD и mini-batch означает исчерпание бюджета эпох (выход на шумовой уровень), а не расходимость: достигнутый риск близок к оптимуму.

Гаусс–Ньютон против Левенберга–Марквардта. Чтобы выявить роль обусловленности, методы сравнены на «сыром» (ненормированном по столбцам) базисе Вандермонда степеней 8 и 12, где число обусловленности гессиана достигает $\kappa \sim 10^5$ и 10^9 (таблица 7).

Таблица 7: Гаусс–Ньютон и Левенберг–Марквардт при плохой обусловленности

Степень	$\kappa(H)$	Метод	Риск Q	Итерации	grad_calls	Сошлось
8	5.26e+05	GN	1.9503e-01	2	2	✓
8	5.26e+05	LM	1.9503e-01	9	9	✓
12	2.39e+09	GN	1.8156e-01	2	2	✓
12	2.39e+09	LM	1.8156e-01	12	12	✓




Рис. 7: Сходимость Гаусса–Ньютона и Левенберга–Марквардта на небусловленном базисе.

Оба метода достигают близкого итогового риска, однако ведут себя по-разному. Гаусс–Ньютон делает один шаг прямого решения системы: при $\kappa \sim 10^9$ этот шаг численно ненадёжен и полностью полагается на устойчивость библиотечного решателя. Левенберг–Марквардт за счёт демпфирования μ строит последовательность гарантированно убывающих по L шагов и потому устойчив к плохой обусловленности; платой служит большее число итераций (9–12 против 2).

7 Выводы

1. Реализованы все требуемые компоненты: генератор двух наборов данных, линейная и полиномиальная модели, четыре варианта функции потерь (L_1 , L_2 , Elastic Net и без регуляризации) и пять методов оптимизации с единым интерфейсом и сохранением истории потерь, риска и регуляризатора.
2. Аналитическое решение, Гаусс–Ньютон и Левенберг–Марквардт дают идентичный минимум наименьших квадратов; для модели, линейной по параметрам, Гаусс–Ньютон эквивалентен нормальным уравнениям и сходится за одну итерацию.
3. Сложность модели нужно согласовывать с данными: нелинейную зависимость с локальным пиком описывает лишь полином степени ≥ 5 , а избыточная степень 9 без регуляризации приводит к переобучению.
4. Размер батча управляет компромиссом «скорость–устойчивость–стоимость»: малые батчи быстрее убывают по эпохам, но шумны и дороги по числу вычислений градиента; наилучшими для рассмотренной задачи оказались средние размеры $|B| = 8\text{--}16$.
5. Регуляризация подавляет переобучение и уменьшает модули коэффициентов; L_1 и Elastic Net дополнительно разрежают решение, тогда как L_2 равномерно сжимает веса.
6. Обусловленность — ключевой фактор: при росте степени полинома κ быстро растёт, из-за чего первопорядковые методы замедляются, прямой шаг Гаусса–Ньютона становится ненадёжным, а демпфирование Левенберга–Марквардта обеспечивает устойчивую сходимость.